

Построение отказоустойчивого распределённого кластера PostgreSQL на базе Citus и Patroni

PostgreSQL. Advanced



Защита проекта

Тема: Построение отказоустойчивого распределённого кластера PostgreSQL на базе Citus и Patroni



Дарья Чистякова

- Senior System Analyst в МТС: проектирую интеграции, веду задачи от требований до прода
- Администратор данных продукта: отвечаю за качество, структуру и управление данными в продукте
- Бакалавр бизнес-информатики (ИТ-менеджмент) и магистр прикладной информатики (DevOps-инженерия)

Цель и задачи проекта

Цель проекта: построить отказоустойчивый распределённый кластер PostgreSQL, способный горизонтально масштабироваться, автоматически восстанавливаться после сбоев узлов и предоставлять единую точку входа для приложений

1. Развернуть инфраструктуру в Yandex Cloud с распределением по трём зонам доступности
2. Настроить кластер etcd (3 узла) как распределённое хранилище конфигураций (DCS) для Patroni
3. Установить PostgreSQL 16, расширение Citus (шардирование) и Patroni (управление репликацией и failover) на 6 узлах БД
4. Сконфигурировать Patroni для двух групп: координаторы (2 узла) и две группы воркеров (по 2 узла в каждой)
5. Проверить работу репликации, автоматического переключения лидера (failover) и распределения шардов Citus
6. Организовать единую точку входа к БД
7. Протестировать отказоустойчивость решения



Какие технологии использовались

1. PostgreSQL 16
2. Citus 12.1
3. Patroni
4. etcd 3.5
5. Yandex Cloud NLB
6. HAProxy 2.8
7. Keepalived




HAProxy



Yandex  Cloud

Архитектура решения



Инфраструктура

- Кластер etcd (3 VM):
etcd-1, etcd-2, etcd-3
- Кластер координаторов (2 VM): citus-coord-1 (primary), citus-coord-2 (standby)
- Кластер воркеров (4 VM): citus-worker-1 (primary), citus-worker-2 (standby), citus-worker-3 (primary), citus-worker-4 (standby)
- Балансировщики нагрузки (2 VM): haproxy-1 и haproxy-2

cloud-dar-chistyakova24 darya Compute Cloud / Виртуальные машины [Создать виртуальную машину](#)

Виртуальные машины

Фильтр по имени Все статусы Все платформы Все зоны доступности Требуется обслуживание

☐	Имя ↓	Идентификатор ↑↓	Cloud Backup	Статус ↑↓	ОС	Платформа ↑↓	vCPU	Доля vCPU	RAM	Прерываемая	Размер дисков	Зона доступности ↑↓	Внутри
☐	haproxy-2	epd9mk8t6r9pu71ns1un	⊗ Не подключён	Running	🔥	Intel Cascade Lake	2	100%	2 Гб	Her	20 Гб	ru-central1-b	10.129 ...
☐	haproxy-1	fhmvsos9sf7kh34arhtn	⊗ Не подключён	Running	🔥	Intel Cascade Lake	2	100%	2 Гб	Her	20 Гб	ru-central1-a	10.128 ...
☐	etcd-3	fv4pjip1nenc7rd9uj17	⊗ Не подключён	Running	🔥	Intel Cascade Lake	2	100%	2 Гб	Her	20 Гб	ru-central1-d	10.130 ...
☐	etcd-2	epdc4md8o466q1sf18oc	⊗ Не подключён	Running	🔥	Intel Cascade Lake	2	100%	2 Гб	Her	20 Гб	ru-central1-b	10.129 ...
☐	etcd-1	fhm4f7dpno93ms62om7b	⊗ Не подключён	Running	🔥	Intel Cascade Lake	2	100%	2 Гб	Her	20 Гб	ru-central1-a	10.128 ...
☐	citus-worker-4	fhm8g5f6f1p78gmub53p	⊗ Не подключён	Running	🔥	Intel Cascade Lake	2	100%	4 Гб	Her	30 Гб	ru-central1-a	10.128 ...
☐	citus-worker-3	fv4ombmd7t97e38c5v	⊗ Не подключён	Running	🔥	Intel Cascade Lake	2	100%	4 Гб	Her	30 Гб	ru-central1-d	10.130 ...
☐	citus-worker-2	epd9dai5f5eq6avd7i12j	⊗ Не подключён	Running	🔥	Intel Cascade Lake	2	100%	4 Гб	Her	30 Гб	ru-central1-b	10.129 ...
☐	citus-worker-1	fhm1va8s52hf371tdrv	⊗ Не подключён	Running	🔥	Intel Cascade Lake	2	100%	4 Гб	Her	30 Гб	ru-central1-a	10.128 ...
☐	citus-coord-2	epd6heq1qrrhv4ci2nh9	⊗ Не подключён	Running	🔥	Intel Cascade Lake	2	100%	4 Гб	Her	30 Гб	ru-central1-b	10.129 ...
☐	citus-coord-1	fhmktejnpub2269cbp92	⊗ Не подключён	Running	🔥	Intel Cascade Lake	2	100%	4 Гб	Her	30 Гб	ru-central1-a	10.128 ...

Настройка NAT-шлюза

ВМ без публичных IP по умолчанию не имеют выхода в интернет. Для установки пакетов и обновлений был создан NAT-шлюз и маршруты для подсетей.

The screenshot displays the Yandex Cloud console interface. The top navigation bar shows the account 'cloud-dar-chistyakova24' and the project 'darya'. The main content area is divided into two sections. The upper section, titled 'Шлюзы' (Gateways), contains a table with one entry: 'nat-gateway' with identifier 'enpkqlu9qr573vr5brca', created on 17.05.2026 at 19:01. The lower section, titled 'Таблицы маршрутизации' (Routing Tables), shows a table with one entry: 'nat-route-table' with identifier 'enpijhtt9v7edcr6ndqo', created on 17.05.2026 at 19:02. A sidebar on the left lists navigation options: default, Облачная сеть, Обзор, Таблицы маршрутизации (selected), Группы безопасности, DNS зоны, and Операции.

cloud-dar-chistyakova24 darya Virtual Private Cloud / Шлюзы

Создать шлюз

Шлюзы

Фильтр по имени или идентификатору

Имя ↑↓	Идентификатор ↑↓	Описание	Дата создания ↑↓	Метки
nat-gateway	enpkqlu9qr573vr5brca	—	17.05.2026, в 19:01	—

cloud-dar-chistyakova24 darya Virtual Private Cloud / Облачные сети / default

Создать таблицу маршрутизации

Таблицы маршрутизации

Фильтр по имени или идентификатору

Имя ↑↓	Идентификатор ↑↓	Описание	Статические маршруты	Дата создания ↑↓	Метки
nat-route-table	enpijhtt9v7edcr6ndqo	—	Префикс назначения: 0.0.0.0/0, Шлюз: nat-gateway	17.05.2026, в 19:02	—

- default
- Облачная сеть
- Обзор
- Таблицы маршрутизации
- Группы безопасности
- DNS зоны
- Операции

Настройка кластера etcd

etcd — хранилище состояния кластера. Patroni использует его для выбора лидера и координации failover

Настройка на трёх нодах:

- Порт 2380 — общение между узлами etcd
- Порт 2379 — клиентские подключения
- Конфигурация задаётся в `/etc/default/etcd`

```
yc-user@etcd-3:~$ sudo systemctl status etcd
● etcd.service - etcd - highly-available key value store
   Loaded: loaded (/usr/lib/systemd/system/etcd.service; enabled; preset: enabled)
   Active: active (running) since Sun 2026-05-17 16:21:37 UTC; 16s ago
     Docs: https://etcd.io/docs
    Main PID: 1930 (etcd)
      Tasks: 8 (limit: 2317)
     Memory: 6.6M (peak: 7.1M)
        CPU: 218ms
    CGroup: /system.slice/etcd.service
            └─1930 /usr/bin/etcd
```

```
yc-user@etcd-1:~$ etcdctl member list
9beb4bc58a190ef, started, etcd-1, http://10.128.0.10:2380, http://10.128.0.10:2379, false
e5c813a6ec7d4b6a, started, etcd-2, http://10.129.0.11:2380, http://10.129.0.11:2379, false
fb03280a094ff223, started, etcd-3, http://10.130.0.12:2380, http://10.130.0.12:2379, false
yc-user@etcd-1:~$
```


Установка PostgreSQL 16, Citus, Patroni на 6 узлах БД

```
yc-user@citus-coord-1:~$ dpkg -l | grep postgresql-16
ii  postgresql-16          16.14-1.pgdg24.04+1      amd64        The World's Most Advanced Open Source Database
ii  postgresql-16-citus-12.1 12.1.10.citus-1          amd64        shard-aware PostgreSQL
yc-user@citus-coord-1:~$ dpkg -l | grep citus
ii  postgresql-16-citus-12.1 12.1.10.citus-1          amd64        shard-aware PostgreSQL
yc-user@citus-coord-1:~$ which patroni
/usr/local/bin/patroni
yc-user@citus-coord-1:~$ patroni --version
patroni 4.1.3
yc-user@citus-coord-1:~$ sudo systemctl status postgresql
○ postgresql.service - PostgreSQL RDBMS
   Loaded: loaded (/usr/lib/systemd/system/postgresql.service; disabled; preset: enabled)
   Active: inactive (dead)

May 17 16:39:08 citus-coord-1 systemd[1]: Starting postgresql.service - PostgreSQL RDBMS...
May 17 16:39:08 citus-coord-1 systemd[1]: Finished postgresql.service - PostgreSQL RDBMS.
May 17 16:41:35 citus-coord-1 systemd[1]: postgresql.service: Deactivated successfully.
May 17 16:41:35 citus-coord-1 systemd[1]: Stopped postgresql.service - PostgreSQL RDBMS.
yc-user@citus-coord-1:~$ sudo systemctl is-enabled postgresql
disabled
yc-user@citus-coord-1:~$ pip3 list | grep -E "patroni|psycopg2"
patroni          4.1.3
psycopg2-binary  2.9.12
```

- Установка PostgreSQL 16, добавление репозитория Citus, замена noble на jammy
- Установка пакетов postgresql-16-citus-12.1, python3-pip
- Установка Patroni: pip install patroni[etcd] psycopg2-binary
- Остановка и отключение стандартного PostgreSQL



Конфигурация Patroni (на 6 узлах)

Для координаторов и для двух групп воркеров создаются конфиги /etc/patroni.yml:

- У координаторов scope: citus_coord, citus.group: 0
- У воркеров первой группы scope: citus_worker_1, citus.group: 1
- У воркеров второй группы scope: citus_worker_2, citus.group: 2

В секции bootstrap указан initdb, необходимые параметры PostgreSQL (shared_preload_libraries = 'citus'), а также post_init скрипт, который при первой инициализации:

- создаёт пользователя replicator
- задаёт пароль postgres
- активирует расширение Citus

```
ssh -i ~/.ssh/bananafrow yc-user@10.128.0.20
sudo tee /etc/patroni.yml <<EOF
scope: citus_coord
name: coord-1

etcd3:
  hosts:
    - "10.128.0.10:2379"

restapi:
  listen: "0.0.0.0:8008"
  connect_address: "10.128.0.20:8008"

bootstrap:
  method: initdb
  initdb:
    - encoding: UTF8
    - data-checksums
  pg_hba:
    - local all all trust
    - host all 127.0.0.1/32 trust
    - host all 0.0.0.0/0 md5
    - host replication replicator 0.0.0.0/0 md5
  post_init: |
    #!/bin/bash
    for i in {1..60}; do
      if /usr/lib/postgresql/16/bin/psql -c "SELECT 1" >/dev/null 2>&1; then
        /usr/lib/postgresql/16/bin/psql -c "CREATE USER replicator WITH REPLICATION PASSWORD 'rep-pass'"
        /usr/lib/postgresql/16/bin/psql -c "ALTER USER postgres PASSWORD 'postgres-pass'"
        /usr/lib/postgresql/16/bin/psql -c "CREATE EXTENSION IF NOT EXISTS citus;" && break
      fi
      sleep 1
    done
  dcs:
    ttl: 30
    loop_wait: 10
    retry_timeout: 10
    maximum_lag_on_failover: 1048576
  postgresql:
    use_pg_rewind: true
    parameters:
      shared_preload_libraries: citus
      wal_level: logical
      max_replication_slots: 10
      max_connections: 200

  postgresql:
    listen: "0.0.0.0:5432"
    connect_address: "10.128.0.20:5432"
    data_dir: /var/lib/postgresql/16/main
    bin_dir: /usr/lib/postgresql/16/bin
    pgpass: /var/lib/postgresql/pgpass
    authentication:
      replication:
        username: replicator
        password: rep-pass
      superuser:
        username: postgres
        password: postgres-pass
    parameters:
      shared_preload_libraries: citus

citus:
  group: 0
  database: postgres

tags:
  nofailover: false
EOF
```



Systemd-сервис Patroni и запуск кластера

- Автоматический запуск Patroni при загрузке узла
- Перезапуск процесса в случае сбоя (failover)
- Централизованное управление и мониторинг через systemd
- Единая конфигурация на всех узлах кластера

```
sudo tee /etc/systemd/system/patroni.service <<EOF
[Unit]
Description=Patroni HA for PostgreSQL
After=network.target

[Service]
Type=simple
User=postgres
Group=postgres
ExecStart=/usr/local/bin/patroni /etc/patroni.yml
Restart=on-failure
RestartSec=5

[Install]
WantedBy=multi-user.target
EOF

sudo systemctl daemon-reload
sudo systemctl enable patroni
```

Список воркеров:

```
postgres=# SELECT * FROM citus_get_active_worker_nodes();
 node_name | node_port
-----+-----
 10.128.0.30 |      5432
 10.130.0.32 |      5432
(2 rows)
```

```
=== Координаторы ===
Enter passphrase for key '/home/yc-user/.ssh/bananaflow':
+ Citus cluster: citus_coord +-----+-----+-----+-----+-----+
| Group | Member | Host | Role | State | TL | Receive LSN | Lag | Replay LSN | Lag |
+-----+-----+-----+-----+-----+
| 0 | coord-1 | 10.128.0.20 | Leader | running | 2 | | | | |
| 0 | coord-2 | 10.129.0.21 | Replica | running | 1 | 0/5000000 | 0 | 0/5006168 | 0 |
+-----+-----+-----+-----+-----+

=== Воркеры группа 1 ===
Enter passphrase for key '/home/yc-user/.ssh/bananaflow':
+ Citus cluster: citus_worker_1 +-----+-----+-----+-----+-----+
| Group | Member | Host | Role | State | TL | Receive LSN | Lag | Replay LSN | Lag |
+-----+-----+-----+-----+-----+
| 1 | worker-1 | 10.128.0.30 | Leader | running | 2 | | | | |
| 1 | worker-2 | 10.129.0.31 | Replica | running | 1 | 0/5000000 | 0 | 0/5021518 | 0 |
+-----+-----+-----+-----+-----+

=== Воркеры группа 2 ===
Enter passphrase for key '/home/yc-user/.ssh/bananaflow':
+ Citus cluster: citus_worker_2 +-----+-----+-----+-----+-----+
| Group | Member | Host | Role | State | TL | Receive LSN | Lag | Replay LSN | Lag |
+-----+-----+-----+-----+-----+
| 2 | worker-3 | 10.130.0.32 | Leader | running | 2 | | | | |
| 2 | worker-4 | 10.128.0.33 | Replica | running | 1 | 0/5000000 | 0 | 0/501F698 | 0 |
+-----+-----+-----+-----+-----+
```

pg_dist_node:

```
postgres=# SELECT nodeid, nodename, nodeport, groupid FROM pg_dist_node;
 nodeid | nodename | nodeport | groupid
-----+-----+-----+-----
      3 | 10.129.0.21 |      5432 |      0
      1 | 10.128.0.20 |      5432 |      0
      5 | 10.128.0.30 |      5432 |      1
      6 | 10.130.0.32 |      5432 |      2
(4 rows)
```



Тестирование распределённой работы Citus и отказоустойчивости Patroni

Останавливаем Patroni на лидере координаторов и на лидерах воркеров. Patroni на репликах автоматически берет на себя роль лидера

```
yc-user@haproxy-1:~$ sleep 20
echo "=== Координаторы ===" && ssh -i ~/.ssh/bananaflow yc-user@10.128.0.20 "sudo patronictl -c /etc/patroni.yml list"
echo "=== Воркеры группа 1 ===" && ssh -i ~/.ssh/bananaflow yc-user@10.128.0.30 "sudo patronictl -c /etc/patroni.yml list"
echo "=== Воркеры группа 2 ===" && ssh -i ~/.ssh/bananaflow yc-user@10.130.0.32 "sudo patronictl -c /etc/patroni.yml list"
=== Координаторы ===
Enter passphrase for key '/home/yc-user/.ssh/bananaflow':
+ Citus cluster: citus_coord +-----+
| Group | Member | Host | Role | State | TL | Receive LSN | Lag | Replay LSN | Lag |
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
| 0 | coord-1 | 10.128.0.20 | Quorum Standby | streaming | 1 | 0/5000398 | 0 | 0/5000398 | 0 |
| 0 | coord-2 | 10.129.0.21 | Leader | running | 1 | | | | |
+-----+-----+-----+-----+-----+-----+-----+-----+
=== Воркеры группа 1 ===
Enter passphrase for key '/home/yc-user/.ssh/bananaflow':
+ Citus cluster: citus_worker_1 +-----+
| Group | Member | Host | Role | State | TL | Receive LSN | Lag | Replay LSN | Lag |
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
| 1 | worker-1 | 10.128.0.30 | Quorum Standby | streaming | 1 | 0/50000C8 | 0 | 0/50000C8 | 0 |
| 1 | worker-2 | 10.129.0.31 | Leader | running | 1 | | | | |
+-----+-----+-----+-----+-----+-----+-----+-----+
=== Воркеры группа 2 ===
Enter passphrase for key '/home/yc-user/.ssh/bananaflow':
+ Citus cluster: citus_worker_2 +-----+
| Group | Member | Host | Role | State | TL | Receive LSN | Lag | Replay LSN | Lag |
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
| 2 | worker-3 | 10.130.0.32 | Quorum Standby | streaming | 1 | 0/50000C8 | 0 | 0/50000C8 | 0 |
| 2 | worker-4 | 10.128.0.33 | Leader | running | 1 | | | | |
+-----+-----+-----+-----+-----+-----+-----+-----+
yc-user@haproxy-1:~$
```

Воркеры:

```
postgres=# SELECT * FROM citus_get_active_worker_nodes();
 node_name | node_port
-----+-----
 10.128.0.33 | 5432
 10.129.0.31 | 5432
(2 rows)
```

Распределение шардов по нодам:

```
postgres=# SELECT n.nodename, count(p.shardid) as shard_count
FROM pg_dist_placement p
JOIN pg_dist_node n ON p.groupid = n.groupid
WHERE p.shardid IN (SELECT shardid FROM pg_dist_shard WHERE logicalrelid = 'test':regclass)
GROUP BY n.nodename;
 nodename | shard_count
-----+-----
 10.128.0.30 | 16
 10.130.0.32 | 16
(2 rows)
```

План запросов по разным шардам:

```
-> Task
Query: SELECT count(*) AS count FROM public.test_102024 test WHERE true
Tuple data received from node: 8 bytes
Node: host=10.128.0.30 port=5432 dbname=postgres
-> Aggregate (actual time=0.057..0.057 rows=1 loops=1)
Output: count(*)
-> Seq Scan on public.test_102024 test (actual time=0.011..0.037 rows=315 loops=1)
Output: id, name
Planning Time: 0.160 ms
Execution Time: 0.077 ms

-> Task
Query: SELECT count(*) AS count FROM public.test_102019 test WHERE true
Tuple data received from node: 8 bytes
Node: host=10.130.0.32 port=5432 dbname=postgres
-> Aggregate (actual time=0.046..0.047 rows=1 loops=1)
Output: count(*)
-> Seq Scan on public.test_102019 test (actual time=0.005..0.027 rows=320 loops=1)
Output: id, name
Planning Time: 0.341 ms
Execution Time: 0.074 ms
```

Обеспечение высокой доступности точки входа (HAProxy + Keeralived + NLB)

- Настроены два экземпляра HAProxy с одинаковой конфигурацией, направляющей трафик на активный координатор через проверку порта 8008
- С помощью Keeralived создан внутренний плавающий VIP 10.128.0.200, который автоматически переключается между HAProxy
- Для доступа из интернета развёрнут Network Load Balancer с публичным IP 37.230.168.30

```
yc-user@haproxy-1:~$ sudo systemctl restart haproxy
yc-user@haproxy-1:~$ sudo systemctl status haproxy
● haproxy.service - HAProxy Load Balancer
   Loaded: loaded (/usr/lib/systemd/system/haproxy.service; enabled; preset: enabled)
   Active: active (running) since Sun 2026-05-17 20:49:42 UTC; 8s ago
     Docs: man:haproxy(1)
           file:/usr/share/doc/haproxy/configuration.txt.gz
   Main PID: 6036 (haproxy)
    Status: "Ready."
     Tasks: 3 (Limit: 2317)
    Memory: 7.5M (peak: 7.7M)
       CPU: 100ms
    CGroup: /system.slice/haproxy.service
            └─6036 /usr/sbin/haproxy -Ws -f /etc/haproxy/haproxy.cfg -p /run/haproxy.pid -S /run/haproxy-master.sock
            └─6039 /usr/sbin/haproxy -Ws -f /etc/haproxy/haproxy.cfg -p /run/haproxy.pid -S /run/haproxy-master.sock
```

```
yc-user@haproxy-1:~$ curl http://10.128.0.20:8008/
{"state": "running", "postmaster_start_time": "2026-05-17 19:56:46.320795+00:00", "role": "primary", "server_version": 160014, "xlog": {"location": 84294952}, "t
": 2, "dcs_last_seen": 1779052778, "database_system_identifier": "7640949689368550097", "patroni": {"version": "4.1.3", "scope": "citux_coord", "name": "coord-1"}
er@haproxy-1:~$ curl curl http://10.129.0.21:8008/
{"state": "running", "postmaster_start_time": "2026-05-17 20:11:48.255674+00:00", "role": "replica", "server_version": 160013, "xlog": {"received_location": 8388
replayed_location": 83911016, "replayed_timestamp": null, "paused": false}, "timeline": 1, "dcs_last_seen": 1779052788, "database_system_identifier": "7640949689
97", "patroni": {"version": "4.1.3", "scope": "citux_coord", "name": "coord-2"}}yc-user@haproxy-1:~$
```

The screenshot shows the AWS Management Console for a Network Load Balancer. The left sidebar contains navigation links for 'nlb-postgres', 'Обзор', 'Операции', and 'Документация'. The main content area is titled 'Обзор' and displays the following details:

- Идентификатор: enp45nhpof0vk91m191a
- Статус: Active
- Имя: nlb-postgres
- Регион: ru-central1
- Тип: EXTERNAL
- Дата создания: 18.05.2026, в 00:14

Below the details, there is a section for 'Размещение' (Placement) with a sub-section 'Управление блокировками зон' (Zone Management). It shows two zones: 'ru-central1-a' and 'ru-central1-b', both with a status of 'Принимает трафик' (Accepts traffic). Below this, there is a table for 'Обработчики' (Listeners):

Имя	Адрес обработчика	Порт	Целевой порт	Протокол
postgres-listener	37.230.168.30	5432	5432	TCP

At the bottom, there is a section for 'Целевые группы' (Target Groups).

Выводы


Связка Patroni + etcd обеспечивает надёжное управление репликацией и автоматический failover в PostgreSQL

Citus позволяет горизонтально масштабировать базу данных путём шардирования без изменений прикладного кода

Сочетание HAProxy + Keepalived + облачного NLB даёт полноценную отказоустойчивую балансировку нагрузки как внутри сети, так и из интернета

Развёртывание в трёх зонах доступности Yandex Cloud повышает устойчивость к сбоям инфраструктуры

Полученная архитектура может служить шаблоном для построения production-решений высокой доступности



Вопросы и рекомендации